Práctica 2: Clasificación de Transacciones

Uso de PLN para Categorización Bancaria

Diego Esclarín & Sofía Contreras

18 de marzo de 2026 | Grado en Ing. en IA | URJC

Índice de Contenidos

1. Introducción y Objetivos

2. Contexto y Métricas

3. Propuesta de Solución

4. Comparativa y Selección Final

5. Conclusiones

INTRODUCCIÓN

El objetivo central es diseñar un sistema basado en **Procesamiento de Lenguaje Natural** capaz de categorizar movimientos bancarios automáticamente.

Utilizamos el **dataset sintético de la primera práctica** implementando algunas mejoras que contemplan diversas formas de redacción, asegurando la robustez del sistema ante variaciones lingüísticas del usuario.

CONTEXTO Y DESAFÍOS

El Problema

La ineficiencia de categorizar manualmente transacciones recurrentes genera fricción y abandono del usuario. Los filtros de texto simples fallan ante cambios mínimos de redacción.

Métricas Clave

Accuracy: Porcentaje total de aciertos.

F1-Score: Equilibrio entre precisión y recuperación, vital para clases minoritarias.

ESTADO DEL ARTE

Vectorización

Uso de **TF-IDF** para asignar relevancia estadística y **Word Embeddings** para relaciones semánticas espaciales.

Arquitecturas

SVM y Random Forest ofrecen robustez en textos cortos y eficiencia frente a Transformers pesados.

Incremental

Importancia del aprendizaje continuo mediante SGD para adaptarse a nuevos patrones sin reentrenar todo.

DATASET UNIFICADO

La calidad de los datos es el pilar de la solución. Combinamos **db_orig.csv** con **db_mod_descript.csv** para doblar los ejemplos por categoría.

También realizamos una depuración y supervisión manual de las descripciones, que nos permitió alcanzar niveles de precisión cercanos a la perfección en entornos controlados.

PIPELINE DE PREPROCESAMIENTO

Limpieza

Conversión a minúsculas y eliminación de caracteres especiales ruidosos para normalizar el corpus.

TF-IDF

Transformación de descripciones textuales en representaciones numéricas basadas en relevancia de términos.

Validación

Partición **50/50** por área para asegurar que el modelo generalice correctamente ante nuevos datos.

DESEMPEÑO DE MODELOS (F1-MACRO)

Validación realizada sobre el Dataset Unificado (50/50 Split)

Conclusiones y Trabajo Futuro

SELECCIÓN FINAL: LINEAR SVM

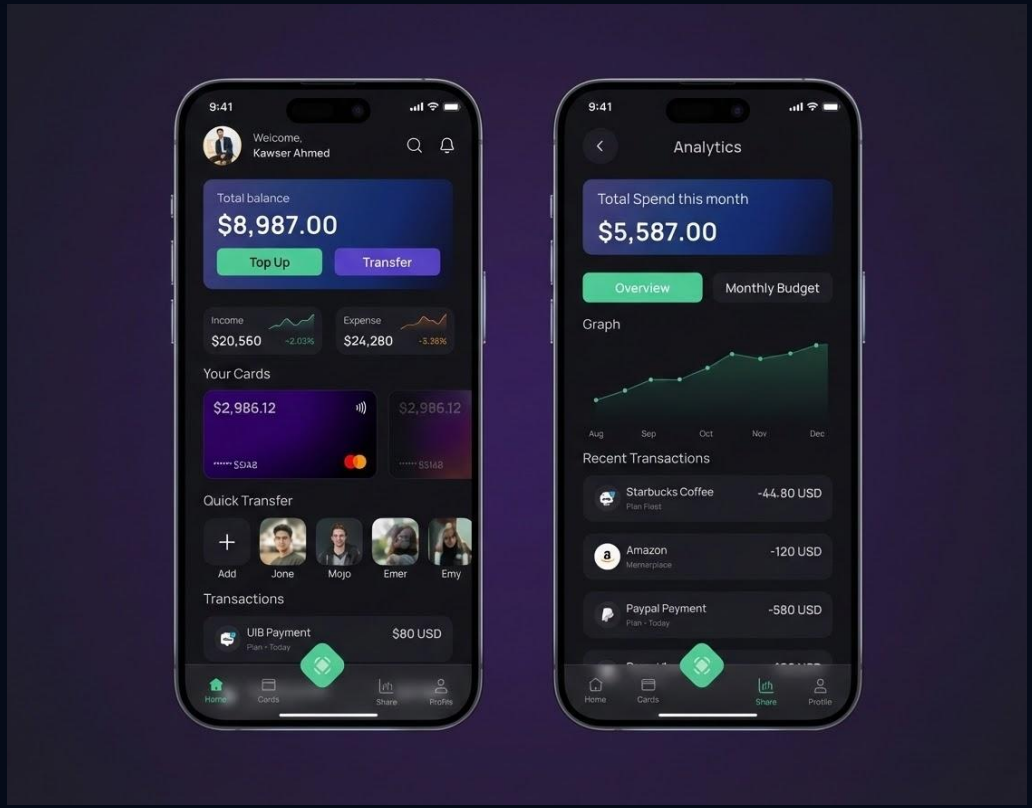

- **F1-Macro de 0.9481:** Excelente separación de clases complejas (Ocio vs Vacaciones).
- **Explicabilidad:** Permite auditar los pesos de las palabras clave por categoría.
- **Eficiencia:** Huella de memoria ligera e inferencia casi instantánea para móvil. Además de reentrenamiento muy rápido.

HALLAZGOS Y PRÓXIMOS PASOS

- **Simplicidad Efectiva:** Los modelos lineales + TF-IDF son altamente competitivos en textos financieros cortos.
- **Unificación Crítica:** La unión de datasets y revisión de descripciones fue la clave para mejorar la robustez ante estilos de redacción.
- **Tuning:** Probar a usar el resto de categorías de la base de datos además de las descripciones para las predicciones.
- **Despliegue:** LinearSVM.joblib está listo para integrarse en el sistema de producción real. Implementar este sistema/aplicación.

¿Preguntas?

Gracias por su atención

Diego Esclarín & Sofía Contreras

Aplicaciones de Inteligencia Artificial | URJC

Móstoles, 18 de marzo de 2026