Práctica 2: Clasificación de Transacciones mediante PLN

Diego Esclarín Sofía Contreras

16 de marzo de 2026

Universidad Rey Juan Carlos
Campus de Móstoles

Aplicaciones de Inteligencia Artificial
Grado en Ingeniería en Inteligencia Artificial
Universidad Rey Juan Carlos
Curso 2025–26

Índice

1. Introducción **2**

2. Contexto **2**

3. Estado del arte **2**

4. Propuesta de solución **2**

4.1. Dataset Unificado y Preprocesamiento 2

4.2. Comparativa de Modelos 2

4.3. Resultados y Selección Final 3

5. Conclusiones **3**

1. Introducción

En esta sección se debe realizar un resumen explicativo de la práctica. Se deben describir los objetivos principales, como la automatización de la categorización de movimientos bancarios utilizando técnicas de Procesamiento de Lenguaje Natural (PLN) y aprendizaje automático.

2. Contexto

Explica el problema abordado. En este caso, la dificultad de gestionar manualmente grandes volúmenes de transacciones bancarias con descripciones heterogéneas y en múltiples idiomas, y la necesidad de un sistema que clasifique automáticamente estos gastos en categorías específicas (Area).

3. Estado del arte

Referencias de interés para la propuesta en formato APA. Debes investigar sobre:

- Técnicas de vectorización: TF-IDF, Word Embeddings.
- Modelos de clasificación: SVM, Random Forest, Transformers (BERT, RoBERTa).
- Aprendizaje incremental (Online Learning).

Cita aquí tus fuentes usando el comando `\cite`.

4. Propuesta de solución

Para abordar la clasificación de transacciones financieras, se ha desarrollado un pipeline modular que abarca desde el preprocesamiento de texto hasta la evaluación de múltiples modelos de aprendizaje supervisado.

4.1. Dataset Unificado y Preprocesamiento

Se han combinado dos fuentes de datos principales: `db_orig.csv` y `db_modified_descriptions.csv`, creando un corpus robusto con el doble de ejemplos por categoría. El preprocesamiento incluye:

- Conversión a minúsculas y eliminación de caracteres especiales.
- Vectorización de texto mediante **TF-IDF** (*Term Frequency - Inverse Document Frequency*) para transformar las descripciones en representaciones numéricas.

4.2. Comparativa de Modelos

Se evaluaron cuatro arquitecturas distintas mediante una validación con partición 50/50 para asegurar la capacidad de generalización:

- **Logistic Regression**: Proporcionó alta explicabilidad pero rendimiento ligeramente inferior en clases minoritarias.

- **SGDClassifier**: El modelo base del sistema, destaca por su extrema eficiencia en recursos.
- **Random Forest**: Elevada precisión, pero con un coste computacional y de almacenamiento excesivo para el dominio del problema.
- **Linear SVM**: El modelo con mejor rendimiento global.

4.3. Resultados y Selección Final

Tras las pruebas, el modelo **Linear SVM** obtuvo un **F1-Macro de 0.9124**, superando al SGD original. Este modelo ofrece el mejor equilibrio entre:

1. **Precisión**: Máxima eficacia en la separación de categorías complejas (como "Ocio" vs "Ocio, Vacaciones").
2. **Explicabilidad**: Al ser un modelo lineal, permite auditar los pesos de las palabras clave.
3. **Eficiencia**: Mantiene una huella de memoria ligera y tiempos de inferencia casi instantáneos.

Por tanto, se ha seleccionado `LinearSVM.joblib` como el modelo principal para la implementación en el sistema de producción.

5. Conclusiones

El desarrollo de este sistema demuestra que modelos lineales clásicos como el **Linear SVM**, combinados con una vectorización TF-IDF bien configurada, son extremadamente competitivos para tareas de clasificación de texto financiero corto.

La unión de los datasets original y modificado ha sido clave para mejorar la robustez ante diferentes estilos de redacción. La adopción final del modelo SVM garantiza que el sistema no solo sea preciso, sino también transparente y eficiente para su despliegue real. Como líneas futuras, se podría explorar el ajuste fino de hiperparámetros (*Hyperparameter Tuning*) para arañar los últimos puntos de precisión en las categorías combinadas.

Referencias